



Ravansad cost estimation

RYAN

گزارش هزینه ماهانه هر کاربر (CBT Chatbot)

سناریو: 20 پیام در روز | 30 روز در ماه | خلاصسازی هر 10,000 توکن به 2,000 توکن

فرضیات استفاده	ترکیب توکن در هر درخواست	نسبت Cache در هر درخواست	مصرف توکن در ماه (برای هر کاربر)
20 پیام در روز	System Prompt 1,000 توکن	70% Cache Hit 30% Cache Miss	ورودی ماهانه 1,830,000 توکن خروجی ماهانه 150,000 توکن (600 درخواست در ماه)
30 روز در ماه	History (مکالمه) + Summary 2,000 توکن		
600 درخواست در ماه	ورودی جدید کاربر 50 توکن		
هر تویت گفتگو (ورودی + خروجی) = 300 توکن	خروجی مدل 250 توکن		
تاریخچه مکالمه هر 10,000 توکن به 2,000 توکن خلاصه می‌شود	جمع کل در هر درخواست 3,300 توکن		

مدل	DeepSeek V4 Flash	DeepSeek V4 Pro	Qwen 3.5 Flash
Context Window	1,000,000 توکن	1,000,000 توکن	1,000,000 توکن
Input Cache Hit Price (به ازای 1M توکن)	\$0.0028	\$0.0145 (2026/05/31 تا تخفیف 75%)	\$0.01 (Explicit Cache Read)
Input Cache Miss Price (به ازای 1M توکن)	\$0.14	\$1.74 (2026/05/31 تا تخفیف 75%)	\$0.10
Output Price (به ازای 1M توکن)	\$0.28	\$3.48 (2026/05/31 تا تخفیف 75%)	\$0.40
Cache Hit (70%) - ورودی ماهانه 1,281,000 توکن	$1,281,000 \times \$0.0028 = \0.0036	$1,281,000 \times \$0.0145 = \0.0186	$1,281,000 \times \$0.01 = \0.0128
Cache Miss (30%) - ورودی ماهانه 549,000 توکن	$549,000 \times \$0.14 = \0.0769	$549,000 \times \$1.74 = \0.9553	$549,000 \times \$0.10 = \0.0549
هزینه ورودی ماهانه	\$0.0805	\$0.9739	\$0.0677
هزینه خروجی ماهانه	$150,000 \times \$0.28 = \0.0420	$150,000 \times \$3.48 = \0.5220	$150,000 \times \$0.40 = \0.0600
هزینه کل ماهانه هر کاربر	\$0.12 به ازای هر کاربر در ماه	\$1.50 به ازای هر کاربر در ماه	\$0.13 به ازای هر کاربر در ماه

خلاصه مقایسه هزینه (به ازای هر کاربر در ماه)			نکات مهم
DeepSeek V4 Flash	\$0.12	★	نسبت Cache برابر با 70% در نظر گرفته شده است.
Qwen 3.5 Flash	\$0.13		هزینه‌ها بر اساس قیمت‌های اعلام‌شده در تاریخ 2026/04/26 و DeepSeek (Qwen) محاسبه شده.
DeepSeek V4 Pro	\$1.50		هزینه‌ها ممکن است با تغییر قیمت‌ها یا تخفیف‌های بعدی تغییر کند.
			این محاسبات برای هر کاربر فعال با الگوی استفاده فوق انجام شده است.

هزینه توکن مصرفی
هر کاربر در تعامل با
چت بات


The price range

0.6 -> 12,000 T
0.12 -> 24,000 T

MULTI-AGENT AI TRANSACTION ANALYSIS: DEEPSEEK-V4-FLASH

~\$0.16 – \$0.22/month
4 run per month

Token cost
For agents



TOKEN USAGE BREAKDOWN

AGENT / NODE	INPUT MISS TOKENS	INPUT HIT TOKENS	OUTPUT TOKENS	TOTAL TOKENS	COST (USD)
Router	7,253	0	2,048	9,301	\$0.001588
Attachment	7,004	768	9,977	17,749	\$0.003786
Schema	76	7,808	10,758	18,642	\$0.003132
Clinical Disorder	1,069	6,528	5,859	13,456	\$0.001882
Cognitive Distortion	968	6,528	5,270	12,766	\$0.001703
Functional Level	961	6,528	9,816	17,305	\$0.002974
Personal Traits	1,233	6,528	6,125	13,886	\$0.001979
Relational Pattern	967	6,528	10,478	17,973	\$0.003160
Meta Analyst	14,848	6,528	5,136	26,512	\$0.003608
TOTAL	34,379	47,744	65,467	147,590	\$0.023812

COST CALCULATION & EFFICIENCY SUMMARY

DEEPSEEK-V4-FLASH
PRICING MODEL
(per 1M tokens)



CACHE HIT
INPUT:
\$0.0002



CACHE MISS
INPUT:
\$0.14




OUTPUT
TOKENS:
\$0.28

DEEPSEEK-V4-FLASH TOTAL COST

CACHE HIT INPUT COST	CACHE HIT INPUT COST Line-item From: image_0.png	\$0.0095488
CACHE MISS INPUT COST	CACHE MISS INPUT COST Distalo From: image_1.png	\$0.0120566
OUTPUT TOKENS COST	OUTPUT TOKENS COST Line-item From: image_1.png	\$0.0022066
GRAND TOTAL		\$0.0238120

TOTAL COST: ~\$0.0238



Token & Cost Analysis Per Patient

High Usage Patient Scenario



Chatbot (User Interactions)

- Input Tokens (Monthly) 2,000,000
- Output Tokens (Monthly) 290,000
- Cache Hit Rate 70%



AI Agents (Background Analysis)

- Input Tokens (Monthly) 63,225
- Output Tokens (Monthly) 27,412
- Cache Hit Rate 45%



Total (Per Patient / Month)

- Total Input Tokens 2,063,225
- Total Output Tokens 317,412
- Overall Cache Hit Rate 68.7%

Total Tokens 2,090,637

Detailed Token Consumption

Category	Input Tokens	Output Tokens	Total Tokens	Cache Hit Rate	Cache Hit Tokens	Cache Miss Tokens
Chatbot (User)	2,000,000	290,000	2,290,000	70%	1,603,000	687,000
AI Agents	63,225	27,412	90,637	45%	40,819	49,818
Total	2,063,225	317,412	2,090,637	68.7%	1,643,819	736,818

Token Distribution



- Chatbot (User) 2,000,000 (95.7%)
- AI Agents 90,637 (4.3%)

درآمد احتمالی سیستم ما



Total Tokens
2,090,637
per patient / month



Overall Cache Hit Rate
68.7%
1,643,819 tokens



Overall Cache Miss Rate
31.3%
736,818 tokens



Estimated Cost / Patient
\$ 0.1374
per month

Cost Breakdown (Per Patient / Month)

Component	Calculation	Cost (USD)
Chatbot Cost	2,000,000 × \$0.0000626	\$0.1252
Agent Cache Hit Cost	40,819 × \$0.00008817	\$0.0036
Agent Cache Miss Cost	49,818 × \$0.00444318	\$0.2214
Agent Output Cost	27,412 × \$0.00767536	\$0.2104
Total Cost / Patient / Month		\$0.1374

Pricing Assumptions

- Cache Hit Cost: \$0.00008817 per 1K tokens
- Cache Miss Cost: \$0.00444318 per 1K tokens
- Output Cost: \$0.00767536 per 1K tokens
- Chatbot Cost: \$0.0000626 per 1K tokens

Revenue vs Cost Comparison (Per Patient / Month)

Revenue (Doctor Subscription)

\$0.60 – \$0.70
per patient / month

Cost (Our Token Usage)

\$0.1374
per patient / month

Profit (Per Patient / Month)

\$0.4626 – \$0.5626
per patient / month

Gross Margin

78.7% – 80.4%

Cost is
19.6% – 21.3%
of Revenue

Profit is

4.6x – 5.6x
Cost



Key Takeaway

Each high-usage patient costs approximately \$0.1374 per month in tokens, while the doctor pays \$0.60 – \$0.70 per patient per month. This results in a strong gross margin of 78.7% – 80.4% and a profit of \$0.4626 – \$0.5626 per patient per month.

Maximum cost per patient

Conversation summarizer	4 (weekly)	\$0.008
Emotional state	4 (weekly)	\$0.004
Doctor notes summarizer	2	\$0.002
Field filler	4 (per visit)	\$0.003
New agents total		~\$0.017 ≈ \$0.02

Soniox cost = 4 × ~\$0.0075 ≈ \$0.03/month

Total Cost

(agents + user conversation)

~\$0.33 – \$0.39

80 , 000 T cost per patient

Income estimation



سود (باحتساب ۸۰ هزار تومن هزینه)	در ماه چهار ویزیت	هر ویزیت (۹۰۰ هزار تومن)	درصد
۲۸ هزار	۱۰۸ هزار	۲۷ هزار	۳٪
۱۰۰ هزار	۱۸۰ هزار	۴۵ هزار	۵٪
۱۷۲ هزار	۲۵۲ هزار	۶۳ هزار	۷٪
۲۸۰ هزار	۳۶۰ هزار	۹۰ هزار	۱۰٪

سود درست	دریافت	درصد
-۵۳,۰۰۰	۲۷,۰۰۰	۳٪
-۳۵,۰۰۰	۴۵,۰۰۰	۵٪
-۱۷,۰۰۰	۶۳,۰۰۰	۷٪
+۱۰,۰۰۰ ✓	۹۰,۰۰۰	۱۰٪




Software architecture

How does conversation of the user get handled




CURRENT SYSTEM OVERVIEW

- Multi-Agent LLM System
LangGraph Orchestration
- LLM: DeepSeek v4-Flash
(for all nodes)
- Input: User Message
(~1850 tokens)
- Per-Agent Output: ~400 tokens
(structured JSON)
- Final Output: Integrated
Clinical Analysis (JSON)




PRODUCTION SCENARIO

HOW IT WORKS IN PRODUCTION



How do we analyze User from history



TOKEN FLOW EXAMPLE









BENEFITS

- ✓ Keeps long-term memory with low token cost
- ✓ Scales to unlimited conversation length
- ✓ Maintains clinical context and continuity
- ✓ Efficient, persistent, and auditable



PROBLEM DEFINITION

User shares private and sensitive conversations with the chatbot.
You want ONLY the doctor (and the system for analysis) to access it,
not the database or developers.




THE PROBLEM: Data is stored in plaintext in the database, so many people or systems can access and read it.



SOLUTION ARCHITECTURE

Conversations are encrypted in the database. Only the Doctor and the authorized system can decrypt and access the data. Reports are also encrypted.



End-to-End Encryption
Data encrypted before storage



Secure Key Management
Keys stored in KMS/Vault, not in the database



Role-Based Access
Only authorized users (doctors/system) can decrypt



Audit Logging
All access is logged and monitored



No Plaintext Storage
Plaintext exists only in memory during use


مزیت رقابتی

رباتی که کاربر باهاش مشاوره می کنه، به دوستاش بده با یه کد معرف ، و زمان بیشتری بتونه چت خوده کاربر ، مشاوره ای که دوستاش میشن با چت بات ، می تونه دکتر رو پیشنهاد بده براشون نوبت با تخفیف بگیره و اصلا می تونه تحلیل کوچیک انجام بده و خودشون بده ،

ما کالا یه چت بات از اول تعریف شده داشته باشیم، کاربر رندوم باید صحبت کنه شهر و سن و چیزای دیگشو بزنه ، پیش مشاوره بشه ... ولی اولویت بندی میشه به دکتری که بیشتر از پلتفرم ما استفاده شده



Use cases ○ Indicates a new use case



*Did not make list of top 100 in 2025
Source: theaiwild.com

